## Vysoká škola ekonomická v Praze Fakulta informatiky a statistiky



# Odhad relativní četnosti binomického rozdělení pomocí klasického a bayesovského přístupu v jazyce R

## BAKALÁŘSKÁ PRÁCE

Studijní program: [Data Analytics]

Autor: [Bc. Michal Lauer]

Vedoucí práce: [Ing. Ondřej Vilikus, Ph.D.]

Praha, Prosinec 2024

Poděkování				
Děkuji svému vedoucímu za odborné neocenitelnou podporu.	vedení práce a p	orůběžné konzulta	ace a své přítelk	zyni za

Klíčová slova	
Bayesovská statistika, odhad relativní četnosti, jazyk R	
Abstract	
Abstract.	
Keywords	
Bayesian statistics, relative frequency estimation, R language	

**Abstrakt** 

Abstrakt.

## Obsah

U.	vod		9	
1	Sta	istické metody	10	
	1.1	Inference	10	
		1.1.1 Problematika výběrových šetření	10	
	1.2	Frekventistická inference	10	
		1.2.1 Testování hypotéz	10	
		1.2.2 Metriky při testování hypotéz	10	
		1.2.3 Jednovýběrový odhad poměru s velkým vzorkem	10	
		1.2.4 Jednovýběrový odhad poměru s malým vzorkem	10	
	1.3	Bayesovská inference	11	
2	Mo	te Carlo generování	12	
	2.1	Vyhodnocení generovaného rozdělení	12	
		2.1.1 Vyhodocení hypotéz	12	
		2.1.2 Odhad poměru	12	
3	Pra	ctické odhady	13	
	3.1	Balíčky pro frekventistickou inferenci	13	
		3.1.1 Klasické test poměru		
	3.2	Software pro bayesovskou statistiku		
		3.2.1 Software BUGS		
		3.2.2 Balíček JAGS	15	
		3.2.3 stan		
	3.3	Simulace		
		3.3.1 Malý vzorek		
		3.3.2 Velký vzorek		
		3.3.3 Porovnání výsledků		
Zá	ivěr		18	
Po	oužit	literatura	19	
Po	Použité balíčky			
		psovská modely	22	

## Seznam obrázků

## Seznam tabulek

# Seznam zdrojových kódů

# Seznam použitých zkratek

**BUGS** Bayesian inference Using Gibbs

Sampling

# Úvod

Tohle je **úvodní** text.

## 1. Statistické metody

Krátký úvod do historie, bayes, inferenční bayes (rozdělení) vs. inference (bod) citace Karla

#### 1.1 Inference

proč to používáme, výběr vs. populace, reprezentativnost

#### 1.1.1 Problematika výběrových šetření

reprezentativnost, definice populace, čas sběru, organizace sběru...

#### 1.2 Frekventistická inference

Jak to funguje, jak to spoléhá na sampling distributions

#### 1.2.1 Testování hypotéz

hladina významnosti, úroveň spolehlivosti, Testovací statistika, kritický obor, 1/2 stranný test p-hodnota, interval spolehlivosti

#### 1.2.2 Metriky při testování hypotéz

Chyba I. a II. druhu, síla testu, velikost efektu

#### 1.2.3 Jednovýběrový odhad poměru s velkým vzorkem

použití, předpoklady, poměrový Z test, binomický test, síla testu, velikost efektu

#### 1.2.4 Jednovýběrový odhad poměru s malým vzorkem

Proč jsou důležité speciální metody, nějaké typy (wiki)

### 1.3 Bayesovská inference

Odvození bayesova vzorce, popis likelihood/aprior/data, druhy aprior/posterior

## 2. Monte Carlo generování

Halsing, Gibs, HMC

#### 2.1 Vyhodnocení generovaného rozdělení

korelace, ESS, monte carlo error...

#### 2.1.1 Vyhodocení hypotéz

Interval kredibility, ROPE, Bayesův faktor

#### 2.1.2 Odhad poměru

## 3. Praktické odhady

#### 3.1 Balíčky pro frekventistickou inferenci

#### 3.1.1 Klasické test poměru

```
Test

test

stats::t.test()

test

Jednoduchý T-test

??

Simulace alfa = chyba 1. druhu
```

#### 3.2 Software pro bayesovskou statistiku

#### 3.2.1 Software BUGS

První software, který se snažil zpopularizovat bayesovské metody je software BUGS (*Bayesian inference Using Gibbs Sampling*). Projekt, jehož cílem bylo vytvořit software pro bayesovskou statistiku, započal už v roce 1989 na oddělní biostatistiky na univerzitě Cambridge a vedl k vytvoření programu BUGS. Postupem času se program vyvynul do nástroje WinBUGS, který je prezentován v této práci (The Bayesian Scientific Working Group, 2024).

Prví verze programu byla představena na Bayesovské konferenci ve Valencii v roce 1991 a později byla distribuovaná na disketách. Z počátku byly implementovány s Gibsovým vzorkováním pouze jendnoduché metody a úpravy, jako adaptivní vzorkování nebo bayesovské inverze. Po čase byla implementována i velmi limitující verze Metropolisova-Hastingova algoritmu, která fungovala na bázi mřížek <sup>1</sup>.

V 90. letech 20. století se projekt přesunul do Imperial College v Londýně a program BUGS se začal vyvíjet i pro osobní počítače se systémem Windows. Do verze WinBUGS se časem implementovala komplexní a plnohodnotná verze Metropolisova-Hestingova algoritmu, která dokázala pracovat bez aproximační tabulky. Velkou sílou však bylo, že uživatel dokázal

<sup>&</sup>lt;sup>1</sup>Jedná se o tzn. *grid-search*, kdy se hledají správné hodnoty v předem definované tabulce.

definovat své apriorní předpoklady, data, vztahy a cykly v grafickém prostředí. Díky tomu mohli program WinBUGS používat i lidé bez zkušeností v programování.

V roce 2004 započala na univerzitě v Helsinách práce na projektu s názvem OpenBUGS, který měl za úkol splnit tři primární cíle:

- rozdělit funkčnost softwaru od jejího vzhledu,
- 2) udělat verzi nezávislou na operačním prostředí, a
- 3) vytvožit experimentálnější prostředí pro zkoušení nových metod.

Pro splnění prvního cíle byl vyvynut nástroj s názevm BRugs. Díky oddělení funkčnosti a vzhledu lze BRugs napojit na další programy jako SAS, Excel nebo R a využívat tak simulací BUGS i mimo jeho prostředí. Ke splnění druhého cíle byla vyvynutá další verze softwaru bugs s názvem LinBUGS pro vývoj v linuxovém prostředí procesory Intel. Experimentální prostředí pro testování nových metod byla vytvořena open-source <sup>2</sup> verze OpenBUGS. Vývoj obou aplikací se časem rozdělil a obě mají silné stránky v něčem jiném. Software OpenBUGS dokáže flexibilně měnit simulační metody nebo simulace provádět paralelně. Vývoj softwaru WinBUGS mířil primárně na excelenci v epidemiologickém a farmakokinetikou.

Aplikace z rodiny BUGS však trpěli několika nedostatky. Tím hlavním je, že jejich vývoj závisí na hrstce vývojářu a i přes to, že je kód (alespoň pro software OpenBUGS) veřejně dostupný, je vývoj problematický. To je způsobeno primárně komplexitou kódu a programovacím jazykem, ve kterém je software napsaný. Druhou velkou nevýhodou je právě programovací jazyk, který se nedokáže vyrovnat např. jazyku C++, ve kterém jsou napsána většina novodobých simulačních programů (Lunn et al., 2009).

V programovacím jazyce R lze s programy BUGS komunikovat pomocí hned několika balíčků. První možností jsou balíčku R2WinBUGS a R2OpenBUGS (Sturtz et al., 2005), které umí komunikovat s programy WinBUGS a OpenBUGS. Jelikož byl balíček OpenBUGS aktualizován naposledy v r. 2020, je smysluplnější v případě zájmu používat balíček R2WinBUGS, který poslední aktualizaci obdržel v r. 2024. Balíčky nenabízejí aplikační přístup, ale slouží jako automatizační pomůcka. Pokud funkcím předáte data, model a parametry simulací, tak se spustí zvolený software (OpenBUGS nebo WinBUGS), do kterého jsou automaticky zvoleny preference uživatel pomocí skriptu. Po dokončení se program sám zavře a výsledky jsou dopstupné v jazyce R.

Druhou možností je balíček BRugs (Thomas et al., 2006), který dokáže komunikovat s OpenBUGS pomocí programatického prostředí a není tedy nutné, aby balíček/funkce na pozadí spouštěli samotné programy. Na rozdíl od balíčku R2WinBUGS, který externě spouští program, je BRugs více flexibilní. Nastavení probíhá pomocí metod, které nastavují, spouští a inicializují jednotlivé řetěze a simulace. Nevýhodou balíčku je, že je nutné ho kompilovat, což může být pro méně zkušené uživatele náročné.

<sup>&</sup>lt;sup>2</sup>software, který má veřejný zdrojový kód; tzn. otevřený software.

 $<sup>^3</sup>$ aktuální k 27. Sprnu, 2024.

#### Balíček {R2WinBUGS}

Výsledek

Odhad parametru p.

Posteriorní rozdělení jednotlivých chainů.

Vývoj jednotlivých chainů.

Autokorelace.

#### 3.2.2 Balíček JAGS

2003 https://www.jstor.org/stable/26447820

JAGS - Just Another Gibbs Sampler

#### Balíček {rjags}

Tvorba modelu

Adaptační doba, která se volá automaticky.

Burn-in generování, je to pro každý chainu.

Generování vzorků z každého chainu.

Základní plot

#### Balíček {R2jags}

Možná úplně vynechat???

Divně spojený bugs and jags.

• Lze komplikovaně nastavit stejný seed

for (i in 1:n.chains) { init.values[[i]] <- inits[[i]] init.values[[i]]. $RNG.name < -RNGnameinit.values[[i]].RNG. <- runif(1, 0, 2^31) }$ 

(asi by to šlo nastavit seed a pak to generovat setjně pomocí runif i nahoře)

• adapt = burnin nebo adapt = 100

if (n.burnin > 0) { n.adapt <- n.burnin } else { n.adapt <- 100 }

• Lze paralelizovat pomocí jags.parallel

Výsledky jsou pořád ze stejného posteriorního rozdělení a jsou validní, akorát se charakteristiky nerovnají.

#### Visualizace

Catterplot.

Posteriorní rozdělení.

Trace plot.

Autokorelace.

#### 3.2.3 stan

Stan 1.0, 2012

http://www.stat.columbia.edu/~gelman/research/published/stan\_jebs\_2.pdf

Stan (není delší název).

aplikace, R implementace, výhody/nevýhody, používá hmc

#### Balíček {rstan}

Model.

```
set.seed(26)
x <- rbinom(10, 1, 0.6)

# stan.model <- rstan::stan(
# model_code = readLines("./kapitoly/modely/stan.txt"),
# model_name = "Jednaoduchý příklad",
# data = list(
# N = length(x), # Počet pozorování
# x = x, # Vstupní data
# alpha = 0.1, # Hodnota parametru alpha
# beta = 0.1 # Hodnota parametru beta
# ),
# init = list(
# list(p = 0.5),</pre>
```

```
# list(p = 0.5)
# ),
# chains = 2,
# iter = 2000 + 5000,
# warmup = 2000,
# thin = 1,
# seed = 59
# )
```

#### 3.3 Simulace

jak budou simulace provedné, jak budou vyhodnocené, nastavení ROPE/alternativ. pro odhad chyb

#### 3.3.1 Malý vzorek

Bayes vs. vybraný vzorec vs. binomic

#### 3.3.2 Velký vzorek

Bayes vs. vybraný vzorec vs. binomic

#### 3.3.3 Porovnání výsledků

Jak testy dopadly

## Závěr

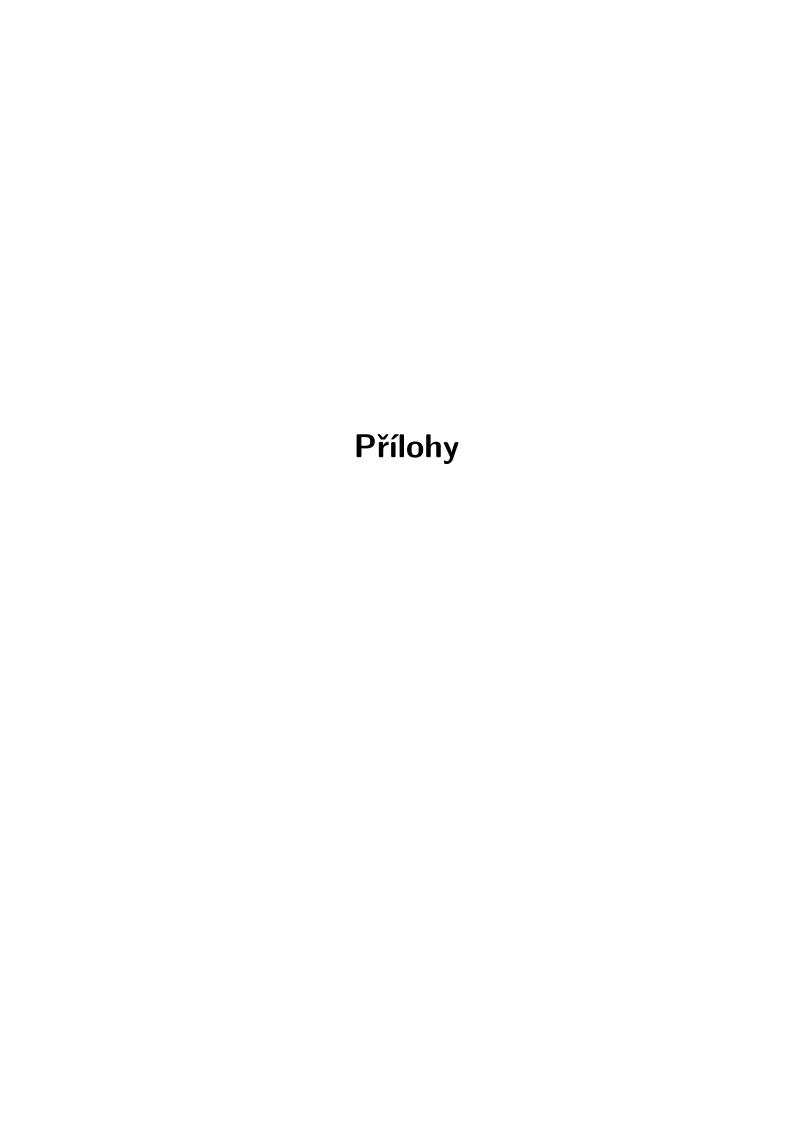
Konec práce, závěr.

## Použitá literatura

- Lunn, D., Spiegelhalter, D., Thomas, A., & Best, N. (2009-11-10). The BUGS project: Evolution, critique and future directions. *Statistics in Medicine*, 28(25), 3049–3067. https://doi.org/10.1002/sim.3680
- The Bayesian Scientific Working Group. (2024-08-26). Bayesian Scientific Work Group Bayesian Scientific Work Group. http://www.bayesianscientific.org/

## Použité balíčky

- Sturtz, S., Ligges, U., & Gelman, A. (2005). R2WinBUGS: A Package for Running WinBUGS from R. Journal of Statistical Software, 12(3), 1–16. https://doi.org/10.18637/jss.v012.i03
- Thomas, A., O'Hara, B., Ligges, U., & Sturtz, S. (2006). Making BUGS Open. R News, 6(1), 12-17. https://cran.r-project.org/doc/Rnews/



# A. Bayesovské modely